

Studiu prin simulare în R

Sîrghe Matei-Ştefan

Popa Mircea

Bujor Ştefan

Afton Ungureanu Robert

26 May 2026

Cuprins

Documentatie Problema 1	2
Cerinta obligatorie	2
Cerinta 1	2
Cerinta 2	2
Cerinta 3	3
Cerinta 4	3
Cerinta 5	4
Cerinta 6	5
Cerinta 7	8
Cerinta 8	10
Cerinta ulterioara	10
Cerinta 1	10
Cerinta 2	11
Cerinta 3	12

Documentatie Problema 1

In aceasta documentatie vom explica cum am rezolvat cerintele si deciziile luate cand vine vorba de rezolvarea acestora

Cerinta obligatorie

Cerinta 1

Am decis sa folosim un dataframe pentru a stoca toate datele care arata astfel:

```
date <- data.frame(  
  zi           = integer(),  
  total        = integer(),  
  normale      = integer(),  
  sus          = integer(),  
  verificate_s = integer(),  
  verificate_a = integer(),  
  verificate_a2 = integer(),  
  detectate_s  = integer(),  
  nedetectate_s = integer(),  
  detectate_a  = integer(),  
  nedetectate_a = integer(),  
  detectate_a2 = integer(),  
  nedetectate_a2 = integer()  
)
```

Cerinta 2

Putem considera ca numarul total de accesuri per zi urmaresc repartitia Poisson, deoarece modelul nostru matematic se bazeaza pe evenimente ce se intampla intr-un interval fix. Puteam alege si alte repartii deoarece nu avem detalii despre cereri, cat timp ne asiguram ca acestea sunt marginite.

Am ales lambda un numar care sa fie mai mare astfel incat simularile sa fie mai apropiate de o situatie mai realistica (i.e. 1000 de accesări în mediu per zi al resursei online).

Numarul de zile ales este aleator, dar din nou dorim un numar mai mare pentru a avea mai multe date deci vom alege un an.

```
lambda <- 1000  
nr_zile <- 365  
  
total <- rpois(nr_zile, lambda)  
head(total)
```

```
[1] 1023 1031 964 957 972 1009
```

Cerinta 3

Vom avea 3 probabilitati definite

```
p      <- 0.01
p2     <- 0.05
p3     <- 0.2
```

Cerinta 4

a) Verificare aleatoare simpla

Pentru testarea și aplicarea celor trei metode de verificare, am ales sa folosim repartizarea hypergeometrica deoarece definitia ei se potriveste pentru situatia noastra unde avem n cereri verificate din N cereri totale, stiind ca k dintre acestea sunt suspecte.

```
proc_verificare <- 10 / 100 #PARAMETRIZABIL
date$verificate_s <- floor(date$total * proc_verificare)
date$detectate_s <- rhyper(
  nn <- nr_zile,
  m = date$sus, # N2
  n = date$normale, #N1
  k = date$verificate_s # actual nr verificate
)
date$nedetectate_s <- date$sus - date$detectate_s

head(date$detectate_s)
```

```
[1] 1 1 0 2 0 0
```

```
head(date$nedetectate_s)
```

```
[1] 12 6 6 12 10 15
```

b) Verificare adaptiva

Crestem procentul odata ce vedem ca numarul de cereri din acea zi este mai mare decat media lambda

```
proc_adapt <- 20 / 100 + abs(date$total - lambda) * 80/100
date$verificate_a <- floor(date$total * proc_adapt / 100)

date$detectate_a <- rhyper(
  nn <- nr_zile,
  m = date$sus, # N2
  n = date$normale, #N1
  k = date$verificate_a # actual nr verificate
)
date$nedetectate_a <- date$sus - date$detectate_a

head(date$detectate_a)
```

```
[1] 5 1 1 3 0 1
```

```
head(date$nedetectate_a)
```

```
[1] 8 6 5 11 10 14
```

c) Verificare propusa

Procedam ca la punctul b doar ca de aceasta data, incercam ceva si mai agresiv care sa identifice mai multe cereri suspecte.

```
proc_adapt2 <- (20 + abs(date$total - lambda) * 0.4) / 100
date$verificate_a2 <- floor(date$total * proc_adapt2)

date$detectate_a2 <- rhyper(
  nn <- nr_zile,
  m = date$sus, # N2
  n = date$normale, #N1
  k = date$verificate_a2 # actual nr verificate
)
date$nedetectate_a2 <- date$sus - date$detectate_a2

head(date$detectate_a2)
```

```
[1] 6 2 1 2 4 4
```

```
head(date$nedetectate_a2)
```

```
[1] 7 5 5 12 6 11
```

Cerinta 5

- Probabilitatea empirică de a detecta cel puțin o cerere suspectă într-o zi

```
vector_logic <- date$detectate_s > 0
prob_empiric <- sum(vector_logic) / length(vector_logic)
prob_empiric
```

```
[1] 0.6082192
```

- Proportia medie de cereri suspecte detectate

```
mean(date$detectate_s / date$sus)
```

```
[1] 0.09670535
```

- Proportia medie de cereri suspecte nedetectate

```
mean(date$nedetectate_s / date$sus)
```

```
[1] 0.9032947
```

- Numarul mediu de verificări efectuate zilnic

```
mean(date$verificate_s)
```

```
[1] 99.67671
```

- Un indicator de eficiență, ales și definit de echipă

Aici am ales ca indicator de eficienta media de cereri suspecte detectate dintre cele verificate.


```
mean(date$detectate_s) / mean(date$verificate_s) * 100
```

```
[1] 0.956517
```

Cerinta 6

- Histograma numărului de cereri suspecte pe zi


```
hist(date$sus,  
     col = "skyblue",  
     border = "black",  
     main = "Histograma date sus",  
     xlab = "Nr. sus",  
     ylab = "Frecventa",  
     breaks = 10  
)
```



- Histograma numărului de cereri suspecte detectate

```
hist(date$detectate_s,  
     col = "salmon",  
     border = "black",  
     main = "Histograma cereri sus detectate per zi",  
     xlab = "Nr. cereri sus detectate",  
     ylab = "Frecventa",  
     breaks = 10  
)
```


Histograma cereri sus detectate per zi



- Grafic comparativ între strategiile de verificare

```
plot(date$zi, cumsum(date$sus), type = "l", col = "red", lwd = 2,
     main = "Grafic comparativ între strategiile de verificare",
     xlab = "Ziua",
     ylab = "Nr. cereri",
     ylim = c(0, max(cumsum(date$sus))))
)
lines(date$zi, cumsum(date$detectate_s), col = "lightblue", lwd = 2)
lines(date$zi, cumsum(date$detectate_a), col = "blue", lwd = 2)
lines(date$zi, cumsum(date$detectate_a2), col = "darkblue", lwd = 2)
legend("topright",
     legend = c(
         "Cereri Suspecte",
         "Cereri Detectate Simplu",
         "Cereri Detectate Adaptiv",
         "Cereri Detectate Adaptiv propus"),
     col = c("red", "lightblue", "blue", "darkblue"),
     lwd = 2
)
```

Grafic comparativ între strategiile de verificare




- Evoluția zilnică a cererilor suspecte și a celor detectate

Am facut un plot pentru zile impartit la numarul decereri:

```
plot(date$zi, date$sus, type = "l", col = "red", lwd = 2,
      main = "Evolutia zilnica a cererilor sus si detectate",
      xlab = "Ziua",
      ylab = "Nr. cereri",
      ylim = c(0, max(date$sus))
)
lines(date$zi, date$detectate_s, col = "blue", lwd = 2)
legend(
  "topright",
  legend = c("Cereri Sus", "Cereri Detectate"),
  col = c("red", "blue"),
  lwd = 2
)
```


Evolutia zilnica a cererilor sus si detectate



Cerinta 7

```
val_sim <- vector("list", nr_zile)

for(i in 1:nr_zile) {
  val_sim[[i]] <- numeric(date$normale[i])
  vector_curent <- val_sim[[i]]
  indici_aleatori <- sample(1:date$normale[i], date$sus[i])
  vector_curent[indici_aleatori] <- 1
  val_sim[[i]] <- vector_curent
}

Calculare_Procent <- function(procent) {
  procent <- procent/100
  prob <- vector("numeric", nr_zile)
  for(i in 1:nr_zile){
    max_range <- date$normale[i]
    num_indexes <- round(date$normale[i]*procent, 1)
    distinct_indexes <- sample(1:max_range, num_indexes)
    prob[i] <- sum(val_sim[[i]][distinct_indexes])/date$sus[i]*100
  }
  return(mean(prob))
}

Repetare_Detect_Sus <- function(numar){
  Medie_y <- c(0,0,0,0,0)
  for(i in 1:numar){
    Medie_y <- Medie_y + c(
      Calculare_Procent(1),
      Calculare_Procent(5),
```

```

    Calcular_Procent(10),
    Calcular_Procent(20),
    Calcular_Procent(30)
  )
}
Medie_y <- Medie_y / numar
return(Medie_y)
}

```

```
x <- c(1,5,10,20,30)
```

```

y <- c(
  Calcular_Procent(1),
  Calcular_Procent(5),
  Calcular_Procent(10),
  Calcular_Procent(20),
  Calcular_Procent(30)
)

```


```
head(y)
```

```
[1] 0.7511534 4.7284130 9.9446712 19.5619288 28.8618807
```

```

plot(x, y, type = "b", col = "blue", pch = 16, lwd = 2,
     main = "Procent cereri suspecte detectate
din numarul total de cereri
la care se aplica media",
     xlab = "Procent Verificate",
     ylab = "Procent Sus Detectate"
)

```



```


y_100 <- Repetare_Detect_Sus(100)
head(y_100)

```

```
[1] 0.9631414 4.9116131 9.9688585 20.0053688 29.9310965
```

```
plot(x, y_100, type = "b", col = "darkblue", pch = 16, lwd = 2,  
     main = "Procent sus detectate din sus total (media toate zilele)",  
     xlab = "Procent Verificate",  
     ylab = "Procent Sus Detectate"  
)
```

Procent sus detectate din sus total (media toate zilele)



Se observa cum prin incercare aleatorie procentul de cereri suspicioase detectate creste linear cu procentul de date verificate dintre cele totale, deci probabilitatea de detectie se schimba linear.

Cerinta 8

In concluzie, se observa cum abordarea simpla aleatorie nu este destul pentru a detecta majoritatea cererilor suspicioase iar o abordare dinamica este necesara pentru a gasi mai multe cereri suspicioase in zilele cu mai multe cereri in general, iar pentru zilele cu mai putine cereri nu avem de ce sa cautam atat de multe cereri suspicioase deoarece nu sunt atat de mult de gasit. Strategia simpla este buna in sensul ca gaseste consistent un numar de cereri suspicioase pe zi raportat la numarul de cereri totale dar daca vrem sa maximizam numarul de cereri suspicioase gasite in raport cu numarul de incercari, atunci abordarea simpla pica.

Cerinta ulterioara

Cerinta 1

```
c_verif <- 1  
c_nedetec <- 1000  
nr_repet <- 1000  
CF_s <- c_verif * date$verificate_s + c_nedetec * date$nedetectate_s  
mean(CF_s)
```

```
[1] 9129.814
```

```
CF_a <- c_verif * date$verificate_a + c_nedetect * date$nedetectate_a
mean(CF_a)
```

```
[1] 8096.773
```

```
CF_a2 <- c_verif * date$verificate_a2 + c_nedetect * date$nedetectate_a2
mean(CF_a2)
```

```
[1] 7235.079
```

Cerinta 2

```
costuri_s <- numeric(nr_repet)
costuri_a <- numeric(nr_repet)
costuri_a2 <- numeric(nr_repet)

for(i in 1:nr_repet){
  set.seed(i)
  date$detectate_s <- rhyper(nn <- nr_zile, m = date$sus, n = date$normale, k = date$verificate_s)
  date$nedetectate_s <- date$sus - date$detectate_s
  costuri_s[i] <- mean(c_verif * date$verificate_s + c_nedetect * date$nedetectate_s)

  date$detectate_a <- rhyper(nn <- nr_zile, m = date$sus, n = date$normale, k = date$verificate_a)
  date$nedetectate_a <- date$sus - date$detectate_a
  costuri_a[i] <- mean(c_verif * date$verificate_a + c_nedetect * date$nedetectate_a)

  date$detectate_a2 <- rhyper(nn <- nr_zile, m = date$sus, n = date$normale, k = date$verificate_a2)
  date$nedetectate_a2 <- date$sus - date$detectate_a2
  costuri_a2[i] <- mean(c_verif * date$verificate_a2 + c_nedetect * date$nedetectate_a2)
}
```

```
head(costuri_s)
```

```
[1] 9127.074 9146.252 9121.595 9110.636 9170.910 8990.088
```

```
head(costuri_a)
```

```
[1] 8063.896 8077.595 7995.403 8173.485 8104.992 8247.458
```

```
head(costuri_a2)
```

```
[1] 7267.956 7273.436 7243.299 7424.121 7224.121 7256.997
```

```
mean(costuri_s)
```

```
[1] 9088.011
```

```
mean(costuri_a)
```

```
[1] 8138.184
```

```
mean(costuri_a2)
```

```
[1] 7272.816
```

```
sd(costuri_s)
```

```
[1] 47.04711
```

```
sd(costuri_a)
```

```
[1] 60.14555
```

```
sd(costuri_a2)
```

```
[1] 73.95381
```

Cerinta 3

Probabilitatiile teoretice sunt valorile exacte obtinute prin demonstratie matematica, folosind teoreme si functii de masa sau densitate de probabilitate. Probabilitatiile simulate sunt valori aproximative obtinute prin simularea unui model de un numar mare de ori si extragerea unori statistici cum ar fi media sau deviata standard din setul de date.