



UNIVERSITATEA DIN
BUCUREȘTI
— VIRTUTE ET SAPIENTIA

Studiu prin simulare în R

Popa Mircea

Sîrghe Matei-Ștefan

Bujor Ștefan

Ungureanu Robert Anton

27 May 2026

Cuprins

Documentatie Problema 1	2
Cerinta obligatorie	2
Cerinta 1	2
Cerinta 2	2
Cerinta 3	3
Cerinta 4	3
Cerinta 5	5
Cerinta 6	6
Cerinta 7	10
Cerinta 8	12
Cerinta ulterioara	12
Cerinta 1	12
Cerinta 2	13
Cerinta 3	52
Documentatie Problema 2	53
Cerinta obligatorie	53
Cerinta 1	53
Cerinta 2	53
Cerinta 3	55
Cerinta 4	56
Cerinta 5	56
Cerinta 6	57
Cerinta 7	57
Cerinta 8	58
Componentă bidimensională obligatorie	58
Cerinta 1	58
Cerinta 2	58
Cerinta 3	59
Cerinta 4	59
Cerinta 5	60
Cerinta 6	60

Documentatie Problema 1

In aceasta documentatie vom explica rezolvarea cerintelor date si deciziile luate in privinta rezolvarii acestora.

Cerinta obligatorie

Cerinta 1

Am decis sa folosim un dataframe pentru a stoca toate datele care arata astfel:

```
date <- data.frame(  
  zi          = integer(),  
  total       = integer(),  
  normale     = integer(),  
  sus         = integer(),  
  verificate_s = integer(),  
  verificate_a = integer(),  
  verificate_a2 = integer(),  
  detectate_s  = integer(),  
  nedetectate_s = integer(),  
  detectate_a  = integer(),  
  nedetectate_a = integer(),  
  detectate_a2 = integer(),  
  nedetectate_a2 = integer()  
)
```

Cerinta 2

Putem considera ca numarul total de accesări per zi urmaresc repartitia Poisson, deoarece modelul nostru matematic se bazeaza pe evenimente independente ce se intampla si sunt numarabile intr-un interval fix, avand adesea o rata medie de aparitie pe care o stim aproximativ constanta. Puteam alege si alte repartii deoarece nu avem detalii despre cereri, cat timp ne asiguram ca acestea sunt marginite.

Am ales lambda un numar care sa fie mai mare astfel incat simularile sa fie mai apropiate de o situatie mai realista (i.e. 1000 de accesări în medie per zi ale resursei online).

Numarul de zile este dat (un an calendaristic).

```
lambda <- 1000  
nr_zile <- 365  
  
total <- rpois(nr_zile, lambda)  
head(total)
```

```
[1] 1000 983 995 964 1059 957
```

Cerinta 3

Vom avea 3 probabilitati definite.

```
p      <- 0.01
p2     <- 0.05
p3     <- 0.2
```

Cerinta 4

a) Verificare aleatoare simpla

Pentru testarea și aplicarea celor trei metode de verificare, am ales sa folosim repartizarea hypergeometrica deoarece definitia ei se potriveste situatiei noastre unde avem n cereri verificate din N cereri totale, stiind ca un numar k dintre acestea sunt suspecte.

```
proc_verificare <- 10 / 100 #PARAMETRIZABIL
date$verificate_s <- floor(date$total * proc_verificare)
date$detectate_s <- rhyper(
  nn <- nr_zile,
  m = date$sus, # N2
  n = date$normale, #N1
  k = date$verificate_s # actual nr verificate
)
date$nedetectate_s <- date$sus - date$detectate_s

head(date$detectate_s)
```

```
[1] 1 2 1 1 0 2
```

```
head(date$nedetectate_s)
```

```
[1] 9 3 8 12 6 10
```

b) Verificare adaptiva 1

Crestem procentul odata ce vedem ca numarul de cereri din acea zi este mai mare decat media lambda.

```
proc_adapt <- 20 / 100 + abs(date$total - lambda) * 80/100
date$verificate_a <- floor(date$total * proc_adapt / 100)

date$detectate_a <- rhyper(
  nn <- nr_zile,
  m = date$sus, # N2
  n = date$normale, #N1
  k = date$verificate_a # actual nr verificate
)
```

Warning in rhyper(nn <- nr_zile, m = date\$sus, n = date\$normale, k = date\$verificate_a): NAs produced

```
date$nedetectate_a <- date$sus - date$detectate_a

head(date$detectate_a)
```

```
[1] 0 0 0 4 2 1
```

```
head(date$nedetectate_a)
```

```
[1] 10  5  9  9  4 11
```

c) Verificare adaptiva 2

Procedam ca la punctul b doar ca de aceasta data, incercam ceva si mai agresiv care sa identifice mai multe cereri suspecte.

```
proc_adapt2 <- (20 + abs(date$total - lambda) * 0.4) / 100
date$verificate_a2 <- floor(date$total * proc_adapt2)
```

```
date$detectate_a2 <- rhyper(
  nn <- nr_zile,
  m = date$sus, # N2
  n = date$normale, #N1
  k = date$verificate_a2 # actual nr verificate
)
date$nedetectate_a2 <- date$sus - date$detectate_a2
```

```
head(date$detectate_a2)
```

```
[1] 5 1 3 3 2 3
```

```
head(date$nedetectate_a2)
```

```
[1]  5  4  6 10  4  9
```

d) Verificare adaptiva bazata pe Z-score (3)

Problema unei probabilitati constante (in cazul nostru 0.01, 0.05 si 0.2) si dorinta minimizarii costului de verificare si ratare a unei cereri suspecte duce la urmatoarele constatari:

- Daca $p \cdot C_{\text{ratare}} > C_{\text{verificare}}$, strategia optima este sa verifichi toate cererile
- Daca $p \cdot C_{\text{ratare}} < C_{\text{verificare}}$, strategia optima este sa nu verifichi nimic.

Pentru aceasta strategie de verificare am incercat sa folosim o functie Sigmoida aplicata pe un scor Z (cate deviatii standard fata de medie are traficul dintr-o zi respectiva). Aceasta tine procentul de verificare mic, adica 10%, in zilele normale, dar va deveni “agresiva” si va creste spre procente mai mari (maxim 85%) pe spike-uri.

Functia logistica standard (sau sigmoida) este de forma:

$$f(x) = \frac{1}{1 + e^{-x}}$$

Adaptata problemei noastre aceasta ia urmatoarea forma:

$$f(x) = \text{procent baza} + \frac{\text{procent maxim} - \text{procent baza}}{1 + e^{-k(x-x_0)}}$$

Unde:

- procent_baza = 10% din cereri minimul, asimptota inferioara a functiei sigmoide
- procent_maxim = 85% din cereri, asimptota superioara a functiei sigmoide
- k = parametrul de “steepness”, care determina cat de abrupta este trecerea din starea normala in starea de alerta, adica detectarea spike-urilor.
- x = metrica pe care o evaluam, adica Z-score

- x_0 = punctul de inflexiune

Pentru cazul nostru, vom considera $k = 2$ si inflexiunea sa fie la 0.

```
base_proc <- 10 / 100
max_proc <- 85 / 100
Z_prag <- 0
steepness <- 2

deviatie_std <- sqrt(lambda)
date$Z_score <- (date$total - lambda) / deviatie_std

proc_risk <- base_proc + (max_proc - base_proc)/(1 + exp(-steepness * (date$Z_score - Z_prag)))

date$verificate_a3 <- floor(date$total * proc_risk)

date$verificate_a3 <- pmin(date$verificate_a3, date$total)

date$detectate_a3 <- rhyper(
  nn <- nr_zile,
  m = date$sus,
  n = date$normale,
  k = date$verificate_a3
)
date$nedetectate_a3 <- date$sus - date$detectate_a3
head(date$nedetectate_a3)
```

```
[1] 4 3 6 10 6 7
```

Cerinta 5

- Probabilitatea empirică de a detecta cel puțin o cerere suspectă într-o zi

```
vector_logic <- date$detectate_s > 0
prob_empiric <- sum(vector_logic) / length(vector_logic)
prob_empiric
```

```
[1] 0.6191781
```

- Proportia medie de cereri suspecte detectate

```
mean(date$detectate_s / date$sus)
```

```
[1] 0.09879267
```

- Proportia medie de cereri suspecte nedetectate

```
mean(date$nedetectate_s / date$sus)
```

```
[1] 0.9012073
```

- Numărul mediu de verificări efectuate zilnic

```
mean(date$verificate_s)
```

```
[1] 99.40548
```

- Un indicator de eficiență, ales și definit de echipă

Aici am ales ca indicator de eficienta media de cereri suspecte detectate dintre cele verificate.


```
mean(date$detectate_s) / mean(date$verificate_s) * 100
```

```
[1] 0.9398341
```

Cerinta 6

- Histograma numărului de cereri suspecte pe zi


```
hist(date$sus,  
      col = "skyblue",  
      border = "black",  
      main = "Histograma date sus",  
      xlab = "Nr. sus",  
      ylab = "Frecventa",  
      breaks = 10  
    )
```



- Histograma numărului de cereri suspecte detectate

```
hist(date$detectate_s,  
      col = "salmon",  
      border = "black",  
      main = "Histograma cereri sus detectate per zi",  
      xlab = "Nr. cereri sus detectate",  
      ylab = "Frecventa",  
      breaks = 10  
    )
```


Histograma cereri sus detectate per zi



- Grafic comparativ între strategiile de verificare

```
plot(date$zi, cumsum(date$sus), type = "l", col = "red", lwd = 2,
      main = "Grafic comparativ între strategiile de verificare",
      xlab = "Ziua",
      ylab = "Nr. cereri",
      ylim = c(0, max(cumsum(date$sus))))
)
lines(date$zi, cumsum(date$detectate_s), col = "lightblue", lwd = 2)
lines(date$zi, cumsum(date$detectate_a), col = "blue", lwd = 2)
lines(date$zi, cumsum(date$detectate_a2), col = "darkblue", lwd = 2)
lines(date$zi, cumsum(date$detectate_a3), col = "cornflowerblue", lwd = 2)
```


Grafic comparativ între strategiile de verificare




- Evoluția zilnică a cererilor suspecte și a celor detectate

Am facut un plot pentru zile impartit la numarul de cereri:


```
plot(date$zi, date$sus, type = "l", col = "red", lwd = 2,
      main = "Evolutia zilnica a cererilor sus si detectate (simpla)",
      xlab = "Ziua",
      ylab = "Nr. cereri",
      ylim = c(0, max(date$sus))
)
lines(date$zi, date$detectate_s, col = "blue", lwd = 2)
```

Evolutia zilnica a cererilor sus si detectate (simpla)



```
plot(date$zi, date$sus, type = "l", col = "red", lwd = 2,  
     main = "Evolutia zilnica a cererilor sus si detectate (adaptiva)",  
     xlab = "Ziua",  
     ylab = "Nr. cereri",  
     ylim = c(0, max(date$sus))  
     )  
lines(date$zi, date$detectate_a3, col = "blue", lwd = 2)
```

Evolutia zilnica a cererilor sus si detectate (adaptiva)



Cerinta 7

```
val_sim <- vector("list", nr_zile)

for(i in 1:nr_zile) {
  val_sim[[i]] <- numeric(date$normale[i])
  vector_curent <- val_sim[[i]]
  indici_aleatori <- sample(1:date$normale[i], date$sus[i])
  vector_curent[indici_aleatori] <- 1
  val_sim[[i]] <- vector_curent
}

Calculare_Procent <- function(procent) {
  procent <- procent/100
  prob <- vector("numeric", nr_zile)
  for(i in 1:nr_zile){
    max_range <- date$normale[i]
    num_indexes <- round(date$normale[i]*procent, 1)
    distinct_indexes <- sample(1:max_range, num_indexes)
    prob[i] <- sum(val_sim[[i]][distinct_indexes])/date$sus[i]*100
  }
  return(mean(prob))
}

Repetare_Detect_Sus <- function(numar){
  Medie_y <- c(0,0,0,0,0)
  for(i in 1:numar){
    Medie_y <- Medie_y + c(
      Calculare_Procent(1),
      Calculare_Procent(5),
      Calculare_Procent(10),
      Calculare_Procent(20),
      Calculare_Procent(30)
    )
  }
  Medie_y <- Medie_y / numar
  return(Medie_y)
}

x <- c(1,5,10,20,30)
y <- c(
  Calculare_Procent(1),
  Calculare_Procent(5),
  Calculare_Procent(10),
  Calculare_Procent(20),
  Calculare_Procent(30)
)
head(y)
```


```
[1] 0.9666238 4.3222599 11.2985670 19.1541444 30.1042673
```

```
plot(x, y, type = "b", col = "blue", pch = 16, lwd = 2,
     main = "Procent cereri suspecte detectate")
```

```

din numarul total de cereri
la care se aplica media",
xlab = "Procent Verificate",
ylab = "Procent Sus Detectate"
)

```



```

y_100 <- Repetare_Detect_Sus(100)
head(y_100)

```

```

[1] 0.9857564 5.0089839 9.8974662 19.8712108 30.1314517


```

```

plot(x, y_100, type = "b", col = "darkblue", pch = 16, lwd = 2,
     main = "Procent sus detectate din sus total (media toate zilele)",
     xlab = "Procent Verificate",
     ylab = "Procent Sus Detectate"
)

```

Procent sus detectate din sus total (media toate zilele)



Se observa cum prin incercare aleatoare procentul de cereri suspecte detectate creste proportional cu procentul de date verificate dintre cele totale, deci probabilitatea de detectie se schimba liniar.

Cerinta 8

In concluzie, se observa cum abordarea simpla aleatoare nu este suficienta pentru a detecta majoritatea cererilor suspecte, iar o abordare dinamica este necesara pentru a gasi mai multe dintre acestea in zilele cu mai multe cereri in general, iar pentru zilele cu un total mai mic nu avem de ce sa cautam atat de multe cereri suspecte, deoarece nu sunt atat de multe de gasit. Strategia simpla este buna in sensul ca gaseste consistent un numar de cereri suspecte pe zi raportat la numarul de cereri totale, dar daca vrem sa maximizam numarul gasit in raport cu numarul de incercari, atunci abordarea simpla pica. Abordarile dinamice au dus la reducerea costului implicat in verificari, deoarece fiecare strategie a incercat sa reactioneze la schimbari fie in raport de medie si deplasari ale acesteia fie prin adaptari la spike-uri de cereri suspecte, strategia optima fiind cea care a utilizat functia sigmoida, care a reusit sa creasca exponential numarul de verificari necesare pe zi in functie de numarul de cereri suspecte.

Cerinta ulterioara

Cerinta 1

```
c_verif <- 1
c_nedetect <- 1000
nr_repet <- 1000
CF_s <- c_verif * date$verificate_s + c_nedetect * date$nedetectate_s
mean(CF_s)
```

```
[1] 9143.241
```

```
CF_a <- c_verif * date$verificate_a + c_nedetect * date$nedetectate_a
mean(CF_a)
```

```
[1] NA
```

```
CF_a2 <- c_verif * date$verificate_a2 + c_nedetect * date$nedetectate_a2
mean(CF_a2)
```

```
[1] 7344.274
```

```
CF_a3 <- c_verif * date$verificate_a3 + c_nedetect * date$nedetectate_a3
mean(CF_a3)
```

```
[1] 5770.726
```

Cerinta 2

```
costuri_s <- numeric(nr_repet)
costuri_a <- numeric(nr_repet)
costuri_a2 <- numeric(nr_repet)
costuri_a3 <- numeric(nr_repet)

for(i in 1:nr_repet){
  set.seed(i)
  date$detectate_s <- rhyper(nn <- nr_zile, m = date$sus, n = date$normale, k = date$verificate_s)
  date$nedetectate_s <- date$sus - date$detectate_s
  costuri_s[i] <- mean(c_verif * date$verificate_s + c_nedetect * date$nedetectate_s)

  date$detectate_a <- rhyper(nn <- nr_zile, m = date$sus, n = date$normale, k = date$verificate_a)
  date$nedetectate_a <- date$sus - date$detectate_a
  costuri_a[i] <- mean(c_verif * date$verificate_a + c_nedetect * date$nedetectate_a)

  date$detectate_a2 <- rhyper(nn <- nr_zile, m = date$sus, n = date$normale, k = date$verificate_a2)
  date$nedetectate_a2 <- date$sus - date$detectate_a2
  costuri_a2[i] <- mean(c_verif * date$verificate_a2 + c_nedetect * date$nedetectate_a2)

  date$detectate_a3 <- rhyper(nn <- nr_zile, m = date$sus, n = date$normale, k = date$verificate_a3)
  date$nedetectate_a3 <- date$sus - date$detectate_a3
  costuri_a3[i] <- mean(c_verif * date$verificate_a3 + c_nedetect * date$nedetectate_a3)
}
```

```
Warning in rhyper(nn <- nr_zile, m = date$sus, n = date$normale, k =
date$verificate_a): NAs produced
Warning in rhyper(nn <- nr_zile, m = date$sus, n = date$normale, k =
date$verificate_a): NAs produced
Warning in rhyper(nn <- nr_zile, m = date$sus, n = date$normale, k =
date$verificate_a): NAs produced
Warning in rhyper(nn <- nr_zile, m = date$sus, n = date$normale, k =
date$verificate_a): NAs produced
Warning in rhyper(nn <- nr_zile, m = date$sus, n = date$normale, k =
date$verificate_a): NAs produced
Warning in rhyper(nn <- nr_zile, m = date$sus, n = date$normale, k =
date$verificate_a): NAs produced
Warning in rhyper(nn <- nr_zile, m = date$sus, n = date$normale, k =
date$verificate_a): NAs produced
Warning in rhyper(nn <- nr_zile, m = date$sus, n = date$normale, k =
date$verificate_a): NAs produced
Warning in rhyper(nn <- nr_zile, m = date$sus, n = date$normale, k =
```



```
Warning in rhyper(nn <- nr_zile, m = date$sus, n = date$normale, k =
date$verificate_a): NAs produced
Warning in rhyper(nn <- nr_zile, m = date$sus, n = date$normale, k =
date$verificate_a): NAs produced
Warning in rhyper(nn <- nr_zile, m = date$sus, n = date$normale, k =
date$verificate_a): NAs produced
Warning in rhyper(nn <- nr_zile, m = date$sus, n = date$normale, k =
date$verificate_a): NAs produced
Warning in rhyper(nn <- nr_zile, m = date$sus, n = date$normale, k =
date$verificate_a): NAs produced
Warning in rhyper(nn <- nr_zile, m = date$sus, n = date$normale, k =
date$verificate_a): NAs produced
Warning in rhyper(nn <- nr_zile, m = date$sus, n = date$normale, k =
date$verificate_a): NAs produced
Warning in rhyper(nn <- nr_zile, m = date$sus, n = date$normale, k =
date$verificate_a): NAs produced
Warning in rhyper(nn <- nr_zile, m = date$sus, n = date$normale, k =
date$verificate_a): NAs produced
Warning in rhyper(nn <- nr_zile, m = date$sus, n = date$normale, k =
date$verificate_a): NAs produced
Warning in rhyper(nn <- nr_zile, m = date$sus, n = date$normale, k =
date$verificate_a): NAs produced
```

```
head(costuri_s)
```

```
[1] 9124.063 9104.885 9115.844 9088.447 9080.227 8995.296
```

```
head(costuri_a)
```

```
[1] NA NA NA NA NA NA
```

```
head(costuri_a2)
```

```
[1] 7396.329 7314.137 7344.274 7429.205 7204.548 7292.219
```

```
head(costuri_a3)
```

```
[1] 5789.904 5735.110 5861.137 5770.726 5754.288 5820.041
```

```
mean(costuri_s)
```

```
[1] 9083.564
```

```
mean(costuri_a)
```

```
[1] NA
```

```
mean(costuri_a2)
```

```
[1] 7295.367
```

```
mean(costuri_a3)
```

```
[1] 5792
```

```
sd(costuri_s)
```

```
[1] 48.15808
```

```
sd(costuri_a)
```

```
[1] NA
```

```
sd(costuri_a2)
```

```
[1] 74.19774
```

```
sd(costuri_a3)
```

```
[1] 73.07693
```

Cerinta 3

Probabilitatile teoretice sunt valorile exacte obtinute prin demonstratie matematica, folosind teoreme si functii de masa sau densitate de probabilitate. Probabilitatile simulate sunt valori aproximative obtinute prin simularea unui model de un numar mare de ori si extragerea unori statistici cum ar fi media sau deviatia standard din setul de date.

Documentatie Problema 2

In realizarea aplicatiei Shiny am folosit urmatoarele pachete: shiny, ggplot2, shinythemes pentru dark-theme si MASS pentru functia mvrnorm.

Cerinta obligatorie

Cerinta 1

Poza cu structura aplicatiei si privire din ansamblu.

Transformări de Variabile Aleatoare Continue

Dimensiunea globală a Eșantionului ($n \geq 10$):
1000

Opțiuni
Alege Repartiția lui X:
Normală (Gaussiană)

$$f(x) = \frac{1}{\sqrt{2\pi}\sigma^2} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Medie (μ):
0

Deviație Standard ($\sigma > 0$):
1

Alege Transformarea $Y = g(X)$:
 $g(x) = x^2$

Generează / Actualizează

Componenta Unidimensională Componenta bidimensională

Distribuția Originală X
Eroare: Deviația standard trebuie să fie strict pozitivă!

Distribuția Transformată Y
Eroare: Deviația standard trebuie să fie strict pozitivă!

Indicatori Statistici pentru X
Eroare: Deviația standard trebuie să fie strict pozitivă!

Indicatori Statistici pentru Y
Eroare: Deviația standard trebuie să fie strict pozitivă!

Interpretare automată:
Eroare: Deviația standard trebuie să fie strict pozitivă!

Cerinta 2

Repartitia normala:

Alege Repartiția lui X:

Normală (Gaussiană)

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

Medie (μ):

0

Deviație Standard ($\sigma > 0$):

1

Repartitia uniforma:

Alege Repartiția lui X:

Uniformă

$$f(x) = \begin{cases} \frac{1}{b-a} & a \leq x \leq b \\ 0 & \text{altfel} \end{cases}$$

Interval $[a, b]$:

-100 -80 -60 -40 -20 0 20 40 60 80 100

-2 -2

Repartitia exponentiala:

Alege Repartiția lui X:

Exponențială

$$f(x) = \begin{cases} \lambda e^{-\lambda x} & x \geq 0 \\ 0 & \text{altfel} \end{cases}$$

Rată ($\lambda > 0$):

1

Repartitia gamma:

Alege Repartiția lui X:

Gamma

$$f(x) = \begin{cases} \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x} & x > 0 \\ 0 & \text{altfel} \end{cases}$$


Formă ($\alpha > 0$):

2

Rată ($\lambda > 0$):

1

Cerinta 3



Cerinta 4

Alege Transformarea $Y = g(X)$:

$g(x) = x^2$

$g(x) = x^2$


$g(x) = |x|$

$g(x) = \log(x)$


$g(x) = e^x$

$g(x) = \sin(x)$

Cerinta 5



Cerinta 6



Cerinta 7

Interpretare automată:	
Indicator	Valoare
Distribuția X	asimetrică pozitiv
Distribuția Y	asimetrică pozitiv
Transformarea a modificat simetria	FALSE
Transformarea a influențat valorile mari prin	extindere
Transformarea a produs	valori strict pozitive
Transformarea a influențat valorile extreme prin	accentuare

Pentru a detecta cum a modificat transformarea simetria, vom rezolva cerinta folosind Coeficientul lui Pearson de asimetrie. Mai intai calculam coeficientul utilizand formula a doua a lui Pearson care utilizeaza mediana:

$$Sk_2 = \frac{3(\bar{X} - M_d)}{s}$$

```
calc_skewness <- function(vec) {
  v <- vec[is.finite(vec)]
  sk <- 3 * (mean(v) - median(v)) / sd(v)
  return(sk)
}
```

Folosind aceasta asimetrie, o putem compara cu o valoare aproape de 0, in cazul nostru aceasta fiind 0,2. Daca e mai mare atunci este asimetrica pozitiv, iar daca e mai mica ca -0,2 atunci este asimetrica negativ, altfel zicem ca aceasta este simetrica. Pentru a vedea daca transformarea a afectat simetria, verificam daca avem acelasi raspuns pentru X si Y si putem da un raspuns.

Ca sa verificam daca transformarea a comprimat valorile mari, vom verifica maximul din X cu maximul din Y.

Ca sa verificam daca transformarea a produs doar valori strict pozitive, doar comparam fiecare valoare cu 0.

Pentru a vedea accentuarea valorilor extreme, ne vom folosi de formulele de baza ale boxplotului. Mai intai calculam iqr pentru X si Y. Dupa calculam numarul de elemente ale lui X care apartin intervalului $(q_1 - 1.5 * iqr, q_3 + 1.5 * iqr)$ si comparam cu numarul de elemente din Y cu aceeasi conditie doar ca utilizam quartilele de la Y. Cand numarul

de elemente din X e mai mare decat numarul de elemente din Y cu aceasta proprietate, avem o diminuare a valorilor extreme, altfel avem o accentuare.

Cerinta 8

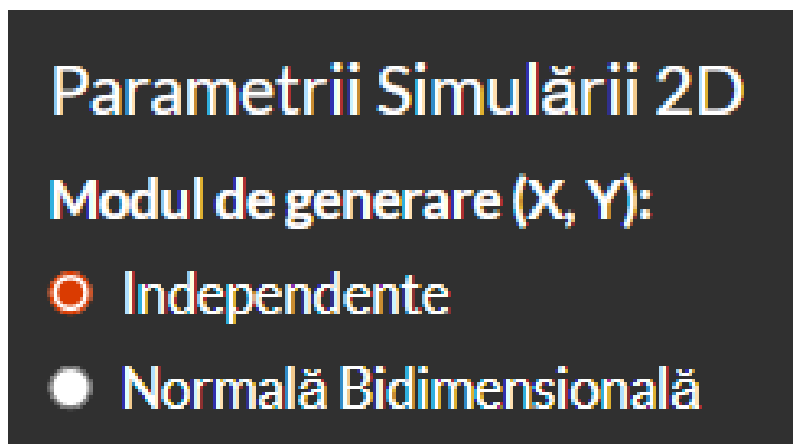
Vom considera $X \sim N(0, 1)$ si transformarile $Y = \log X$ si $Y = e^X$.

Transformarea $Y = e^X$ transforma valorile negative ale lui X in valori subunitare ($0 < e^X < 1$) si pe cele pozitive in valori supraunitare. In acest caz, Y va fi mereu pozitiva, asimetrica spre dreapta. Valorile mari sunt rare dar pot fi foarte mari.


Transformarea $Y = \log(X)$ este problematica deoarece $\log(x)$ nu este definita pentru valori mai mici sau egale cu 0. Deoarece X ia valori negative cu o probabilitate de 50%, aceasta transformare este invalida pe jumatate din domeniu. Aplicatia noastra elimina in acest caz valorile care sunt fie NaN, fie infinite.

Componentă bidimensională obligatorie

Cerinta 1



Cerinta 2



☒ Normală Bidimensională

Media lui X (μ_X):

Media lui Y (μ_Y):


Deviația Std lui X ($\sigma_X > 0$):

Deviația Std lui Y ($\sigma_Y > 0$):


Coefficient de corelație (ρ):

Cerinta 3


Scatterplot Perechi (X, Y)




Histograma Transformării $Z = h(X, Y)$



Histograma X



Histograma Y



Cerinta 4

Alege Transformarea $Z = h(X, Y)$:

$Z = X + Y$

$Z = X + Y$

$Z = X - Y$

$Z = X * Y$

$Z = \sqrt{X^2 + Y^2}$

Cerinta 5

Indicator	Valoare	Indicator	Valoare
Covarianță Empirică (X,Y)	-0.00591077327368719	Medie Empirică	-0.0223
Coeficient de Corelație (X,Y)	-0.00565594331399868	Dispersie Empirică	2.0819
		Deviație Standard Empirică	1.4429
		Minim	-4.7095
		Q1 (25%)	-1.0464
		Mediană (50%)	-0.0029
		Q3 (75%)	0.9886
		Maxim	4.8202


Indicator	Valoare	Indicator	Valoare
Medie Empirică	0.0273	Medie Empirică	-0.0496
Dispersie Empirică	0.9858	Dispersie Empirică	1.1079
Deviație Standard Empirică	0.9929	Deviație Standard Empirică	1.0526
Minim	-2.4270	Minim	-3.6097
Q1 (25%)	-0.6476	Q1 (25%)	-0.7841
Mediană (50%)	0.0484	Mediană (50%)	-0.0135
Q3 (75%)	0.6629	Q3 (75%)	0.6743
Maxim	3.0470	Maxim	3.9056

Cerinta 6

Parametrul de corelație are un efect direct, liniar și proporțional asupra covarianței. Având abaterile standard σ_X și σ_Y constante, influența lui ρ este următoarea:

- Dacă $\rho = 0$ covarianța tinde spre 0, indiferent de mărimea abaterilor standard. Cele două variabile nu prezintă o tendință liniară de a crește sau scădea împreună. Norul de puncte este circular sau o elipsă ușoară.

Scatterplot Perechi (X, Y)



Indicator

Valoare

Covarianță Empirică (X,Y)


0.00676354417182671

Coeficient de Corelație (X,Y)

0.00665417641081049

- Dacă $\rho = 0.5$ covarianța devine pozitivă. Creșterea parametrului mărește direct proporțional covarianța. Norul de puncte ia o formă elipsoidală spre dreapta-sus, indicând faptul că valorile mari ale lui X tind să fie asociate cu valori mari ale lui Y.

Scatterplot Perechi (X, Y)



Indicator	Valoare
Covarianță Empirică (X,Y)	0.505558203360397
Coeficient de Corelație (X,Y)	0.515467657019738

- Dacă $\rho = -0.5$ covarianța devine negativă. Pe măsura ce parametrul se apropie de -1, covarianța scade. Norul de puncte ia o formă elipsoidală și se înclină spre dreapta-jos, indicând faptul că valorile mari ale lui X sunt asociate cu valori mici ale lui Y.

Scatterplot Perechi (X, Y)



Indicator	Valoare
Covarianță Empirică (X,Y)	-0.508240150659652
Coeficient de Corelație (X,Y)	-0.508527831705237